

多项式插值与函数最佳逼近

Lagrange 插值

很熟悉了啊.

Th 4.1

插值多项式唯一.

n 次 Lagrange 插值多项式, 记为 $L_n(x)$, 形式为

$$L_n(x) = \sum_{k=0}^n f(x_k) \prod_{i \neq k} \frac{x - x_i}{x_k - x_i}.$$

Th 4.2

给出 n 个互异点, 存在唯一的次数不超过 n 的多项式 $L_n(x_i)$ 满足 $L_n(x_i) = f(x_i), (i = 0, \dots, n)$.

称 $R_n(x) = f(x) - L_n(x)$ 为插值多项式的余项.

Th 4.3

对余项的估计, 很像 Taylor 公式中的 Lagrange 余项.

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i).$$

一些说明:

1. $\xi \in \left(\min_{1 \leq i \leq n} \{x_i\}, \max_{1 \leq i \leq n} \{x_i\} \right)$.
2. 当 $f(x)$ 本身是一个次数不超过 n 的多项式的时候, 余项等于零.

差商, Newton 插值

先说差商. 考虑 Lagrange 插值中, 增加或减少节点对插值多项式的影响.

设 $L_{k-1}(x)$ 是 x_0, x_1, \dots, x_{k-1} 为插值节点的多项式, L_k 是 x_0, x_1, \dots, x_k 为插值节点的多项式.

令

$$g(x) = L_k(x) - L_{k-1}(x),$$

那么 $g(x)$ 是一个次数不超过 k 的多项式, 且对 $i = 0, 1, \dots, k-1$ 都有 $g(x_i) = 0$.

则可以设

$$g(x) = a_k(x - x_0)(x - x_1) \cdots (x - x_{k-1}).$$

其中 a_k 是一个常数.

(但是我有一个疑问, 如果插值的第 k 个点是 $(x_k, 0)$ 怎么办)

接着就有

$$L_k(x) = a_0 + a_1(x - x_0) + a_2(x - x_0)(x - x_1) + \cdots + a_k(x - x_0)(x - x_1) \cdots (x - x_{k-1}).$$

其中

$$a_k = \sum_{m=0}^k \frac{f(x_m)}{\prod_{i=0, i \neq m}^k (x_m - x_i)}.$$

Def 4.2

设

$$f[x_i, x_j] = \frac{f(x_j) - f(x_i)}{x_j - x_i}$$

为 $f(x)$ 关于点 x_i, x_j 的 1 阶差商.

设

$$f[x_i, x_j, x_k] = \frac{f[x_j, x_k] - f[x_i, x_j]}{x_k - x_i}$$

为 $f(x)$ 关于点 x_i, x_j, x_k 的 2 阶差商.

类似地, 可以定义 k 阶差商为

$$f[x_0, x_1, \cdots, x_{k-1}, x_k] = \frac{f[x_1, x_2, \cdots, x_{k-1}, x_k] - f[x_0, x_1, \cdots, x_{k-2}, x_{k-1}]}{x_k - x_0}.$$

约定 0 阶差商即为函数值.

性质:

1. $f[x_0, x_1, \cdots, x_k] = \sum_{m=0}^k \frac{f(x_m)}{\prod_{i=0, i \neq m}^k (x_m - x_i)}.$
2. k 阶差商的值与点的顺序无关, 这一点从上面的表达式也可以看出来.

接着就是 Newton 插值多项式了.

$$L_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \cdots + f[x_0, x_1, \cdots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}).$$

差分, 等距节点插值

在等距条件下, 差商会有更简单的表示, 也就是差分. 设等距节点 $x_k = x_0 + kh (k = 0, 1, \cdots, n)$, h 称为步长.

这里定义一些线性算子:

1. 向前差分算子: $\Delta f_k = f_{k+1} - f_k,$
2. 向后差分算子: $\nabla f_k = f_k - f_{k-1},$
3. 中心差分算子: $\delta f_k = f_{k+1/2} - f_{k-1/2},$

4. 位移算子: $E f_k = f_{k+1}$.

接着就可以得到:

$$1. \Delta^n f_k = (E - I)^n f_k = \sum_{j=0}^n (-1)^j C_n^j E^{n-j} f_k = \sum_{j=0}^n (-1)^j C_n^j f_{n+k-j}.$$

$$2. \nabla^n f_k = (I - E^{-1})^n f_k = \sum_{j=0}^n (-1)^{n-j} C_n^j E^{j-n} f_k = \sum_{j=0}^n (-1)^{n-j} C_n^j f_{j+k-n}.$$

$$3. f_{n+k} = E^n f_k = (I + \Delta)^n f_k = \sum_{j=0}^n C_n^j \Delta^j f_k.$$

$$4. f[x_k, x_{k+1}, \dots, x_{k+m}] = \frac{1}{m!} \frac{1}{h^m} \Delta^m f_k.$$

$$5. f[x_k, x_{k-1}, \dots, x_{k-m}] = \frac{1}{m!} \frac{1}{h^m} \nabla^m f_k.$$

Hermite 插值多项式

之前的插值都是只有函数值的情形.

Def 4.3

给定闭区间 $[a, b]$ 中的 $n+1$ 个互异点 x_i 处的函数值以及直到 m_i 阶导数值, 设 $m = \sum_{i=0}^n (m_i + 1) - 1$, 可以得到一个次数不超过 m 的多项式 $H_m(x)$, 称为 $f(x)$ 的 m 次 Hermite 插值多项式.

Th 4.4

自然 m 次多项式 $H_m(x)$ 是唯一的.

Th 4.5

$$\text{余项 } R_m(x) = f(x) - H_m(x) = \frac{f^{(m+1)}(\xi)}{(m+1)!} \prod_{i=0}^n (x - x_i)^{m_i+1}.$$

Newton 型 Hermite 插值多项式

补充定义差商:

$$f[x_0, x_0] = f'(x_0) \text{ 以及 } f[x_0, x_0, x_1] = \frac{f[x_0, x_1] - f[x_0, x_0]}{x_1 - x_0}, \text{ 那么差值结果如下:}$$

$$\begin{aligned} H_m(x) = & f(x_0) + f[x_0, x_0](x - x_0) + \cdots + \underbrace{f[x_0, \dots, x_0]}_{m_0+1} (x - x_0)^{m_0} + \\ & \underbrace{f[x_0, \dots, x_0, x_1]}_{m_0+1} (x - x_0)^{m_0+1} + \cdots + \\ & \underbrace{f[x_0, \dots, x_0, x_1, \dots, x_1]}_{m_0+1} (x - x_0)^{m_0+1} \underbrace{(x - x_1)^{m_1}}_{m_1+1} + \cdots + \\ & \underbrace{f[x_0, \dots, x_0, \dots, x_{n-1}, \dots, x_{n-1}, x_n]}_{m_0+1} (x - x_0)^{m_0+1} \cdots (x - x_{n-1})^{m_{n-1}+1} + \cdots + \\ & \underbrace{f[x_0, \dots, x_0, \dots, x_{n-1}, \dots, x_{n-1}, x_n, \dots, x_n]}_{m_0+1} (x - x_0)^{m_0+1} \cdots (x - x_{n-1})^{m_{n-1}+1} (x - x_n)^{m_n}, \end{aligned}$$

高次插值的缺点以及分段低次插值

(先挖坑)

三次样条插值

Def 4.5

给定闭区间 $[a, b]$ 上的 $n + 1$ 个插值点, 如果函数 $S(x)$ 满足:

1. $S(x_i) = y_i$,
2. $S(x)$ 在每一个小区间上都是三次多项式,
3. $S(x) \in C^2[a, b]$,

就称 $S(x)$ 是 $f(x)$ 的三次样条插值.

首先判断一下需要多少个条件, 每一个小区间需要确定 4 个参数, 也就是一共需要 $4n$ 个.

再计算一下条件数. 由于 $S(x)$ 是 $C^2[a, b]$ 的, 这就意味着对于小区间之间的分界点, 两侧的函数值, 一阶导数和二阶导数的极限要相等. 加上插值条件, 这里一共 $(n + 1) + 3(n - 1) = 4n - 2$ 个.

这自然是还要补充两个条件, 通常有如下三种, 分别被称为第一型, 第二型和第三型:

1. 两端点的导数,
2. 两端点的二阶导数,
3. 周期边界, 也就是当 $f(x_0) = f(x_n)$ 时, $S'(x_0 + 0) = S'(x_n - 0)$, $S''(x_0 + 0) = S''(x_n - 0)$.

一通暴算最后可以得到:

$$\mu_i M_{i-1} + 2M_i + \lambda_i M_{i+1} = d_i, \quad i = 1, 2, \dots, n-1,$$

其中

$$\begin{aligned} M_i &= S''(x_i), \\ h_i &= x_{i+1} - x_i, \\ \mu_i &= \frac{h_{i-1}}{h_{i-1} + h_i}, \\ \lambda_i &= \frac{h_i}{h_{i-1} + h_i}, \\ d_i &= 6f[x_{i-1}, x_i, x_{i+1}]. \end{aligned}$$

第一型

利用 $S'(x_0) = f'(x_0)$, $S'(x_n) = f'(x_n)$ 可以得到

$$\begin{pmatrix} 2 & 1 & & & \\ \mu_1 & 2 & \lambda_1 & & \\ & \mu_2 & 2 & \lambda_2 & \\ & & \ddots & \ddots & \ddots \\ & & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & & 1 & 2 \end{pmatrix} \begin{pmatrix} M_0 \\ M_1 \\ M_2 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_0 \\ d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}.$$

第二型

利用 $M_0 = f''(x_0), M_n = f''(x_n)$ 可以得到

$$\begin{pmatrix} 2 & \lambda_1 & & & \\ \mu_2 & 2 & \lambda_2 & & \\ & \mu_3 & 2 & \lambda_3 & \\ & & \ddots & \ddots & \ddots \\ & & & \mu_{n-2} & 2 & \lambda_{n-2} \\ & & & & \mu_{n-1} & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ M_3 \\ \vdots \\ M_{n-2} \\ M_{n-1} \end{pmatrix} = \begin{pmatrix} d_1 - \mu_1 f''(x_0) \\ d_2 \\ d_3 \\ \vdots \\ d_{n-2} \\ d_{n-1} - \lambda_{n-1} f''(x_n) \end{pmatrix}.$$

第三型

利用 $S'(x_0) = S'(x_n), S''(x_0) = S''(x_n)$ 可以得到

$$\begin{pmatrix} 2 & \lambda_1 & & & \mu_1 \\ \mu_2 & 2 & \lambda_2 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ \lambda_n & & & \mu_n & 2 \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ \vdots \\ M_{n-1} \\ M_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}.$$

这都是很好解的.

给出三次条样函数的误差估计.

Th 4.8

$$\|f^{(k)} - S^{(k)}\|_{\infty} \leq c_k \|f^{(4)}\|_{\infty} \left(\max_{0 \leq i \leq n-1} (x_{i+1} - x_i) \right)^{4-k}, k = 0, 1, 2,$$

其中 $c_0 = \frac{1}{16}, c_1 = c_2 = \frac{1}{2}$.

最佳一致逼近

Def 4.6

线性空间

Def 4.7

线性赋范空间

Def 4.8

距离

Def 4.9

最佳逼近元

Def 4.10

记 $M_n = \{p_n \mid p_n \text{ 为次数不超过 } n \text{ 的多项式}\}$, 则 $M_n \subset C[a, b]$. 设 $f \in C[a, b]$. 若 $\exists p_n \in M_n$, 使得对 $\forall q_n \in M_n$, 有

$$\|f - p_n\|_\infty \leq \|f - q_n\|_\infty,$$

则称 $p_n(x)$ 是 $f(x)$ 的 n 次最佳一致逼近多项式.

因为是一致逼近, 所以选择 L^∞ 范数.

Th 4.11

对于 $f \in C[a, b]$, 在 M_n 中一定存在最佳一致逼近多项式.

两个条件, 闭区间和连续函数.

Def 4.12

称满足 $x_0 \in [a, b]$, $|g(x_0)| = \|g\|_\infty$ 的点 x_0 为 $g(x)$ 在 $[a, b]$ 上的偏差点.

若 $g(x_0) = \|g\|_\infty$ 的 x_0 为正偏差点, 否则为负偏差点.

Lemma

如果 $f \in [a, b]$, $p_n(x)$ 是其 n 次最佳一致逼近多项式, 那么 $f - p_n$ 一定存在正负偏差点.

(why 提到了 切比雪夫多项式?)

最佳平方逼近

Def 4.13

内积空间

Def 4.14

正交

Lemma

Cauchy - Schwartz 不等式

Th 4.15

将 Th 4.10, 也就是最佳一致逼近中的 $\|\cdot\|_\infty$ 改为 $\|\cdot\|_2$ 就得到了最佳平方逼近. 泛函里学过, 最佳平方逼近是有唯一解的, 并且给出了计算方式.

离散数据的最佳平方逼近

对于给定数据

Error: Unknown environment 'tabular'

如果选取基 $\varphi_k(x) = x^k$, 得到的 m 次最佳平方逼近多项式被称为 m 次最小二乘多项式.

记

$$\varphi_k = \begin{pmatrix} \varphi_k(x_1) \\ \varphi_k(x_2) \\ \vdots \\ \varphi_k(x_n) \end{pmatrix}, \quad k = 0, 1, \dots, m, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix},$$

那么 m 次最小二乘多项式的系数就是下面线性方程组的解

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_m) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_m) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_m, \varphi_0) & (\varphi_m, \varphi_1) & \cdots & (\varphi_m, \varphi_m) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_m \end{pmatrix} = \begin{pmatrix} (\mathbf{y}, \varphi_0) \\ (\mathbf{y}, \varphi_1) \\ \vdots \\ (\mathbf{y}, \varphi_m) \end{pmatrix}.$$

超定线性方程组的最小二乘解

对于线性方程组

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix},$$

其中 $n < m$, 且系数矩阵的列向量线性无关, 这样的线性方程组称为超定方程组.

这样的方程组一般没有精确解.

记

$$\mathbf{A}_j = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{pmatrix}, \quad j = 1, 2, \dots, n, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix},$$

那么上述方程组可被写成

$$x_1 \mathbf{A}_1 + x_2 \mathbf{A}_2 + \cdots + x_n \mathbf{A}_n = \mathbf{b}.$$

还是利用泛函的东西.

记 $M = \text{span}\{\mathbf{A}_1, \mathbf{A}_2, \dots, \mathbf{A}_n\}$, 那么 M 是 \mathbb{R}^m 的一个有限维子空间, 那么设

$$\Phi(x_1, x_2, \dots, x_n) = \left\| \mathbf{b} - \sum_{i=1}^n x_i \mathbf{A}_i \right\|^2,$$

就一定要有 $(x_1^*, x_2^*, \dots, x_n^*)$ 使得

$$\Phi(x_1^*, x_2^*, \dots, x_n^*) = \min_{x_i \in \mathbb{R}} \Phi(x_1, x_2, \dots, x_n).$$

根据之前的理论知道, $(x_1^*, x_2^*, \dots, x_n^*)$ 其实就是下面方程的解

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}.$$

连续函数的最佳平方逼近

$$\begin{pmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_m) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_m) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_m, \varphi_0) & (\varphi_m, \varphi_1) & \cdots & (\varphi_m, \varphi_m) \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_m \end{pmatrix} = \begin{pmatrix} (y, \varphi_0) \\ (y, \varphi_1) \\ \vdots \\ (y, \varphi_m) \end{pmatrix}.$$

依旧是成立的, 只需要注意内积变成函数的内积.