

计算方法

北京师范大学数学科学学院

主讲人：纪光华

Email: ghji @bnu.edu.cn

第三章、线性方程组的数值解法

本章主要内容

1. Gauss消去法, Gauss列主元消去法
2. 向量和矩阵的范数, 方程组的性态和误差估计
3. Jacobi迭代、Gauss-Seidel迭代格式, 收敛性的判别
4. 幂法和反幂法

3.1 Cramer法则

考虑一般的线性方程组

$$\mathbf{Ax} = \mathbf{b}, \quad (1)$$

其中

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

如果 $\det \mathbf{A} \neq 0$ 则方程组(1)有唯一解 $x_i = \frac{D_i}{D} (i = 1, \dots, n)$.

- ▶ 计算量: $(n+1) * n!(n-1) = (n-1)(n+1)!$ 次乘法,
当 $n = 100$ 时, $100! \times 99 \approx 9.24 \times 10^{159}$;
- ▶ 神威·太湖之光 (4): 93015 TFlop/s, 3.15×10^{135} 年;
- ▶ Fugaku (富岳): 442010 TFlop/s;
- ▶ Summit: 148600 TFlop/s;
- ▶ <https://www.chinastor.com/hpc-top500/>

3.2 Gauss消去法

思想：利用线性代数中学习过的初等行变换将方程组化为等价的三角形方程组.

★Gauss消去法

将方程 $\mathbf{Ax} = \mathbf{b}$ 用增广矩阵表示, 记

$$\bar{\mathbf{A}}^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} & a_{2,n+1}^{(1)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} & a_{n,n+1}^{(1)} \end{bmatrix},$$

其中

$$a_{ij}^{(1)} = a_{ij}, \quad i, j = 1, 2, \cdots, n; \quad a_{i,n+1}^{(1)} = b_i, \quad i = 1, 2, \cdots, n.$$

下面用 $n-1$ 步消元（初等行变换）将矩阵 $\bar{\mathbf{A}}^{(1)}$ 化为上三角矩阵.

1) 第1步消元：假设 $a_{11}^{(1)} \neq 0$ （否则交换两行的位置），

记 $l_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}}$ ，第1行乘 $-l_{i1}$ 加到第行 i ($2 \leq i \leq n$)行得

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & a_{i2}^{(2)} & \cdots & a_{in}^{(2)} & a_{i,n+1}^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} & a_{n,n+1}^{(2)} \end{bmatrix}$$

其中

$$a_{ij}^{(2)} = a_{ij}^{(1)} - l_{i1}a_{1j}^{(1)}, \quad i = 2, 3, \dots, n, \quad j = 2, 3, \dots, n+1.$$

2) 假设按上面进行了 $k-1$ 步消元，即有

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \cdots \longrightarrow \bar{\mathbf{A}}^{(k)},$$

其中 $\bar{\mathbf{A}}^{(k)}$

$$= \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n+1}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{i,k}^{(k)} & \cdots & a_{i,n}^{(k)} & a_{i,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n+1}^{(k)} \end{bmatrix}$$

3) 第 k 步消元: 假设 $a_{kk}^{(k)} \neq 0$ (否则交换两行的位置),

记 $l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$, 第 k 行乘 $-l_{ik}$ 加到第 i ($k+1 \leq i \leq n$)行得

$$= \begin{matrix} \bar{\mathbf{A}}^{(k)} \longrightarrow \bar{\mathbf{A}}^{(k+1)} \\ \left[\begin{array}{cccccccc} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k}^{(1)} & a_{1,k+1}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k}^{(2)} & a_{2,k+1}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k}^{(3)} & a_{3,k+1}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{kk}^{(k)} & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k+1}^{(k+1)} & \cdots & a_{k+1,n}^{(k+1)} & a_{k+1,n+1}^{(k+1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+2,k+1}^{(k+1)} & \cdots & a_{k+2,n}^{(k+1)} & a_{k+2,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{i,k+1}^{(k+1)} & \cdots & a_{i,n}^{(k+1)} & a_{i,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{n,k+1}^{(k+1)} & \cdots & a_{nn}^{(k+1)} & a_{n,n+1}^{(k+1)} \end{array} \right] \end{matrix}$$

其中

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik}a_{kj}^{(k)},$$
$$i = k + 1, k + 2, \dots, n, \quad j = k + 1, k + 2, \dots, n + 1. (2)$$

4) 总共进行 $n - 1$ 步($k = 1, 2, \dots, n - 1$)消元后,

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \dots \longrightarrow \bar{\mathbf{A}}^{(k)} \longrightarrow \dots \longrightarrow \bar{\mathbf{A}}^{(n)},$$

其中

$$\bar{\mathbf{A}}^{(n)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ & & \ddots & \vdots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} & a_{n-1,n+1}^{(n-1)} \\ & & & & a_{nn}^{(n)} & a_{n,n+1}^{(n)} \end{bmatrix}. \quad (3)$$

若记

$$\mathbf{U} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} \\ & & \ddots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} \\ & & & & a_{nn}^{(n)} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{n-1,n+1}^{(n-1)} \\ a_{n,n+1}^{(n)} \end{bmatrix},$$

则(3)对应的线性方程组为 $\mathbf{U}\mathbf{x} = \mathbf{y}$, 用回代可求得 \mathbf{x} .

消元过程乘除法次数 $\frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6}$, 加减法次数 $\frac{n^3}{3} - \frac{n}{3}$.

★ 三角形方程组的回代法
考虑三角形方程组

$$\begin{array}{ccccccc} u_{11}x_1 + & u_{12}x_2 + & \cdots + & u_{1,n-1}x_{n-1} + & u_{1n}x_n & = & y_1 \\ & u_{22}x_2 + & \cdots + & u_{2,n-1}x_{n-1} + & u_{2n}x_n & = & y_2 \\ & & \ddots & \cdots & \cdots & & \\ & & & & u_{n-1,n-1}x_{n-1} + & u_{n-1,n}x_n & = y_{n-1} \\ & & & & & u_{nn}x_n & = y_n \end{array}$$

其中 $u_{ii} \neq 0 (i = 1, 2, \dots, n)$. 用下面的回代法求解:

$$\begin{aligned} x_n &= y_n / u_{nn}, \\ x_i &= \left(y_i - \sum_{j=i+1}^n u_{ij}x_j \right) / u_{ii}, \quad i = n-1, n-2, \dots, 1. \end{aligned}$$

计算量: 乘除法: $\frac{n(n+1)}{2}$ 、加减法: $\frac{n(n-1)}{2}$.

可以估计, Gauss消元法解线性方程组(1)需要加减法和乘除法次数均为 $O(n^3)$.

定理3.1

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$. 如果 \mathbf{A} 的各阶顺序主子式非零, 则 Gauss消去法中的各主元 $a_{kk}^{(k)} (k = 1, 2, \dots, n)$ 均非零.

★三对角方程组的追赶法 考虑三对角方程组

$$\begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \ddots & \ddots & \ddots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix} \quad (4)$$

其系数矩阵元素满足

1. $|b_1| > |c_1| > 0$;
2. $|b_i| \geq |a_i| + |c_i|, \quad a_i c_i \neq 0 (i = 2, 3, \dots, n-1)$;
3. $|b_n| > |a_n| > 0$.

方程组(4)的系数矩阵非奇异. 利用Gauss消去法解方程组(4), 每步消元只要消一个元素.

三消元过程算法如下:

$$\beta_1 = b_1, \quad y_1 = d_1,$$

$$l_i = \frac{a_i}{\beta_{i-1}}, \quad \beta_i = b_i - l_i c_{i-1}, \quad y_i = d_i - l_i y_{i-1} \quad (i = 2, 3, \dots, n).$$

$$\begin{bmatrix} \beta_1 & c_1 & & & & \\ & \beta_2 & c_2 & & & \\ & & \beta_3 & c_3 & & \\ & & & \ddots & \ddots & \\ & & & & \beta_{n-1} & c_{n-1} \\ & & & & & \beta_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{n-1} \\ y_n \end{bmatrix}$$

回代算法:

$$x_n = y_n / \beta_n,$$

$$x_i = (y_i - c_i x_{i+1}) / \beta_i \quad (n = n-1, n-2, \dots, 1).$$

追赶法计算次数, 乘除法: $5n-4$ 次, 加减法: $3n-3$ 次;

★列主元Gauss消去法 第 k 步消元: 假设 $a_{kk}^{(k)} \neq 0$ (否则交换两行的位置), 记 $l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$, 第 k 行乘 $-l_{ik}$ 加到第 i ($k+1 \leq i \leq n$)行得

$$\bar{\mathbf{A}}^{(k)} \longrightarrow \bar{\mathbf{A}}^{(k+1)}$$

$$= \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k}^{(1)} & a_{1,k+1}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k}^{(2)} & a_{2,k+1}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k}^{(3)} & a_{3,k+1}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{kk}^{(k)} & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k+1}^{(k+1)} & \cdots & a_{k+1,n}^{(k+1)} & a_{k+1,n+1}^{(k+1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+2,k+1}^{(k+1)} & \cdots & a_{k+2,n}^{(k+1)} & a_{k+2,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{i,k+1}^{(k+1)} & \cdots & a_{i,n}^{(k+1)} & a_{i,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{n,k+1}^{(k+1)} & \cdots & a_{nn}^{(k+1)} & a_{n,n+1}^{(k+1)} \end{bmatrix}$$

其中

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik}a_{kj}^{(k)}, \\ i = k + 1, k + 2, \dots, n, \quad j = k + 1, k + 2, \dots, n + 1. (5)$$

由(5)看出, 在Gauss消去法中, 当 $|l_{ik}|$ 很大(如 $|a_{kk}^{(k)}|$ 很小)时, 元素 a_{kj} 很小的误差, 将导致元素 $a_{ij}^{(k+1)}$ 较大的误差. 所以希望 $|l_{ik}| \leq 1$.

设进行了 $k-1$ 步消元.

$$\bar{\mathbf{A}}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{i,k}^{(k)} & \cdots & a_{i,n}^{(k)} & a_{i,n}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n}^{(k)} \end{bmatrix}$$

在第 k 步消元之前, 从第 k 列位于对角线以下的元素中选绝对值最大者作为主元.

如果

$$|a_{sk}^{(k)}| = \max_{k \leq i \leq n} |a_{ik}^{(k)}|,$$

即 (s, k) 元素绝对值最大, 则交换第 s 行和第 k 行对应元素, 然后进行消元. 显然此时有

$$|l_{ik}| = \left| \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} \right| \leq 1.$$

例3.1

用列主元 *Gauss* 消去法求下列方程组的解.

$$\begin{bmatrix} 3 & 1 & -1 \\ 4 & 0 & 4 \\ 12 & -3 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 8 \\ 9 \end{bmatrix}.$$

解:

$$\begin{aligned} \begin{bmatrix} 3 & 1 & -1 & 4 \\ 4 & 0 & 4 & 8 \\ 12 & -3 & 3 & 9 \end{bmatrix} &\xrightarrow{r_1 \leftrightarrow r_3} \begin{bmatrix} 12 & -3 & 3 & 9 \\ 4 & 0 & 4 & 8 \\ 3 & 1 & -1 & 4 \end{bmatrix} \begin{array}{l} r_2 + (-\frac{1}{3})r_1 \\ r_3 + (-\frac{1}{4})r_1 \end{array} \\ \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & 1 & 3 & 5 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \end{bmatrix} &\xrightarrow{r_2 \leftrightarrow r_3} \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \\ 0 & 1 & 3 & 5 \end{bmatrix} \xrightarrow{r_3 + (-\frac{4}{7})r_2} \\ \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \\ 0 & 0 & 4 & 4 \end{bmatrix} &. \end{aligned}$$

$$x_3 = 1, \quad x_2 = 2, \quad x_1 = 1.$$

3.2 矩阵的LU分解

Gauss消去法第一步消元相当于 $\mathbf{L}_1\bar{\mathbf{A}}^{(1)} = \bar{\mathbf{A}}^{(2)}$, 其中矩阵

$$\mathbf{L}_1 = \begin{bmatrix} 1 & & & & \\ -l_{21} & 1 & & & \\ -l_{31} & 0 & 1 & & \\ \vdots & \vdots & & \ddots & \\ -l_{n1} & 0 & & \cdots & 1 \end{bmatrix}$$

以此类推得 $\mathbf{L}_{n-1}\mathbf{L}_{n-2}\cdots\mathbf{L}_1\bar{\mathbf{A}}^{(1)} = \bar{\mathbf{A}}^{(n)}$, 即 $\mathbf{L}_{n-1}\mathbf{L}_{n-2}\cdots\mathbf{L}_1(\mathbf{A}|b) = (\mathbf{U}|y)$. 记 $\mathbf{L} = \mathbf{L}_1^{-1}\cdots\mathbf{L}_{n-1}^{-1}$ 可得 $\mathbf{A} = \mathbf{LU}$

定理3.2

如果 \mathbf{A} 的各阶顺序主子式非零, 则对 \mathbf{A} 可作唯一的LU分解。

★LU分解

$$u_{1j} = a_{1j}, (j = 1, 2, \dots, n+1)$$

$$l_{i1} = \frac{a_{i1}}{a_{11}}, (i = 2, 3, \dots, n),$$

$$u_{kj} = a_{kj} - \sum_{q=1}^{k-1} l_{kq} u_{qj}, (j = k, k+1, \dots, n+1),$$

$$l_{ik} = \left(a_{ik} - \sum_{q=1}^{k-1} l_{iq} u_{qk} \right) / u_{kk}, (i = k+1, k+2, \dots, n)$$

Remark:

1. 对称矩阵的LU分解-计算量减少一半.
2. 列选主元LU分解.

3.3 方程组的性态与误差分析

例3.2

考虑方程组

$$\begin{bmatrix} 1 & -1 \\ 1 & \mathbf{1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为 $x_1 = x_2 = 1$.

设方程组系数有小扰动, 方程组成为

$$\begin{bmatrix} 1 & -1 \\ 1 & \mathbf{1.0005} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为 $x_1 = x_2 = 0.99975006$.

该例子说明矩阵误差对解的影响不大.

例3.3

考虑方程组

$$\begin{bmatrix} 10 & -10 \\ -1 & 1.001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为 $x_1 = x_2 = 1$.

同样, 若系数有误差, 方程组变为

$$\begin{bmatrix} 10 & -10 \\ -1 & 1.0015 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为 $x_1 = x_2 = \frac{2}{3}$.

这个例子说明方程组的系数矩阵的误差对解的影响很大. 问题: 怎么判别?

★向量范数

设 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbf{R}^n$.

定义3.1

设 $f(\mathbf{x}) = \|\mathbf{x}\|$ 是 \mathbf{R}^n 上的函数, 如果满足:

1. (非负性) $\forall \mathbf{x} \in \mathbf{R}^n$, 有 $\|\mathbf{x}\| \geq 0$, 且 $\|\mathbf{x}\| = 0 \Leftrightarrow \mathbf{x} = \mathbf{0}$;
2. (齐次性) $\forall \mathbf{x} \in \mathbf{R}^n, \lambda \in \mathbf{R}$, 有 $\|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|$;
3. (三角不等式) $\forall \mathbf{x}, \mathbf{y} \in \mathbf{R}^n$, 有 $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$.

则称 $\|\cdot\|$ 为 \mathbf{R}^n 上的范数.

常用的三个向量范数:

1. 1-范数: $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$;
2. ∞ -范数: $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$;
3. 2-范数: $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{(\mathbf{x}, \mathbf{x})}$.

由范数定义的三角不等式易得

$$|\|\mathbf{x}\| - \|\mathbf{y}\|| \leq \|\mathbf{x} - \mathbf{y}\|.$$

定理3.3

设 $f(\mathbf{x}) = \|\mathbf{x}\|$ 为 \mathbf{R}^n 上的任意一个向量范数, 则 $f(\mathbf{x})$ 为 \mathbf{x} 分量的连续函数. 即

$$\lim_{\mathbf{x} \rightarrow \mathbf{y}} f(\mathbf{x}) = f(\mathbf{y}).$$

定义3.2

设 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 是 \mathbf{R}^n 上两个范数. 如果存在正常数 c_1, c_2 使得对 $\forall \mathbf{x} \in \mathbf{R}^n$, 有

$$c_1 \|\mathbf{x}\|_p \leq \|\mathbf{x}\|_q \leq c_2 \|\mathbf{x}\|_p,$$

则称范数 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 等价.

定理3.4

\mathbf{R}^n 上任意两个范数都等价.

定义3.3

设 $\|\cdot\|$ 是 \mathbf{R}^n 上的范数, $\mathbf{x}, \mathbf{y} \in \mathbf{R}^n$, 称 $\|\mathbf{x} - \mathbf{y}\|$ 为 \mathbf{x} 和 \mathbf{y} 之间的距离.

利用距离可以研究向量的绝对误差和相对误差. 设 \mathbf{x}^* 是精确

值(向量), \mathbf{x} 是 \mathbf{x}^* 的近似值(向量) 则称 $\|\mathbf{x}^* - \mathbf{x}\|$ 和 $\frac{\|\mathbf{x}^* - \mathbf{x}\|}{\|\mathbf{x}^*\|}$

或 $\frac{\|\mathbf{x}^* - \mathbf{x}\|}{\|\mathbf{x}\|}$ 表示近似解 \mathbf{x} 的绝对误差和相对误差.

定义3.4

设 $\|\cdot\|$ 是 \mathbf{R}^n 中的一个范数, $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots$ 是 \mathbf{R}^n 中的一个向量序列, $\mathbf{c} \in \mathbf{R}^n$ 为常向量. 如果

$$\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{c}\| = 0,$$

则称向量序列 $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ 收敛于 \mathbf{c} , 记为

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{c}.$$

★矩阵范数 设

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix},$$

$\|\cdot\|$ 为 \mathbf{R}^n 上的一个范数.

定义3.5

称

$$\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$$

为矩阵 \mathbf{A} 的范数, 记为 $\|\mathbf{A}\|$. 即

$$\|\mathbf{A}\| = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$$

最大值 $\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$ 能否取到? 由定理3.3知, 对 $\forall \mathbf{x} \in \mathbf{R}^n$,

$\|\mathbf{Ax}\|$ 在 \mathbf{R}^n 上连续. 记

$$\mathbf{S} = \{\mathbf{y} | \mathbf{y} \in \mathbf{R}^n, \|\mathbf{y}\| = 1\},$$

\mathbf{S} 是有界闭集. $\|\mathbf{Ax}\|$ 在 \mathbf{S} 上能取到最大值, 设最大值为 M . 即存在 $\mathbf{y}_0 \in \mathbf{S}$ 使得

$$\max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = \|\mathbf{Ay}_0\| = M.$$

故对 $\forall \mathbf{x} \in \mathbf{R}^n, \mathbf{x} \neq 0$, 有 $\frac{\mathbf{x}}{\|\mathbf{x}\|} \in \mathbf{S}$, 令 $\mathbf{y} = \frac{\mathbf{x}}{\|\mathbf{x}\|}$, 有

$$\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = M.$$

矩阵范数的性质：设 $\|\cdot\|$ 是一个矩阵范数，则有

1. $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$, $\|\mathbf{A}\| \geq 0$, 且 $\|\mathbf{A}\| = 0 \Leftrightarrow \mathbf{A} = \mathbf{0}$.
2. $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$, $\lambda \in \mathbf{R}$, 有 $\|\lambda \mathbf{A}\| = |\lambda| \|\mathbf{A}\|$.
3. $\forall \mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$, 有 $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$.
4. $\forall \mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$, 有 $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$.
5. $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$, $\mathbf{x} \in \mathbf{R}^n$, 有 $\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \|\mathbf{x}\|$.

定义3.6

设 $\mathbf{B} \in \mathbf{R}^{n \times n}$, $\lambda_1, \lambda_2, \dots, \lambda_n$ 为 \mathbf{B} 的 n 个特征值. 称

$$\rho(\mathbf{B}) = \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

为矩阵 \mathbf{B} 的谱半径.

定理3.5

设 $\mathbf{A} \in \mathbf{R}^{n \times n}$, 则

1.

$$\|\mathbf{A}\|_1 = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1} = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|.$$

2.

$$\|\mathbf{A}\|_\infty = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

3.

$$\|\mathbf{A}\|_2 = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} = \sqrt{\rho(\mathbf{A}^T \mathbf{A})}.$$

定理3.6

设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的任意一个矩阵范数, $\mathbf{A} \in \mathbf{R}^{n \times n}$, 则有

$$\rho(\mathbf{A}) \leq \|\mathbf{A}\|.$$

定理3.7

如果 $\mathbf{A} \in \mathbf{R}^{n \times n}$ 为对称矩阵, 则 $\rho(\mathbf{A}) = \|\mathbf{A}\|_2$.

定义3.7

设 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 为 $\mathbf{R}^{n \times n}$ 上的两个范数, 如果存在正常数 c_1, c_2 , 使得对 $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$ 有

$$c_1 \|\mathbf{A}\|_p \leq \|\mathbf{A}\|_q \leq c_2 \|\mathbf{A}\|_p.$$

则称 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 等价.

定理3.8

$\mathbf{R}^{n \times n}$ 上任意两个矩阵范数都等价.

定义3.8

设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的矩阵范数, $\mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$, 称 $\|\mathbf{A} - \mathbf{B}\|$ 为 \mathbf{A} 与 \mathbf{B} 之间的距离.

定义3.9

设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的矩阵范数, $\mathbf{A}^{(0)}, \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(k)}, \dots$ 为 $\mathbf{R}^{n \times n}$ 上的一个矩阵序列, $\mathbf{A} \in \mathbf{R}^{n \times n}$. 如果

$$\lim_{k \rightarrow \infty} \|\mathbf{A}^{(k)} - \mathbf{A}\| = 0,$$

则称矩阵序列 $\{\mathbf{A}^{(k)}\}_{k=0}^{\infty}$ 收敛于矩阵 \mathbf{A} , 记为

$$\lim_{k \rightarrow \infty} \mathbf{A}^{(k)} = \mathbf{A}.$$

定理3.9

设 $\mathbf{B} \in \mathbf{R}^{n \times n}$, 则矩阵序列 $\mathbf{I}, \mathbf{B}, \mathbf{B}^2, \dots, \mathbf{B}^k, \dots$ 收敛于零矩阵(即 $\lim_{k \rightarrow \infty} \mathbf{B}^k = \mathbf{0}$)的充要条件是 $\rho(\mathbf{B}) < 1$.

条件数

设 \mathbf{A} 非奇异, $\mathbf{b} \neq \mathbf{0}$, 方程组 $\mathbf{Ax} = \mathbf{b}$ 的精确解为 \mathbf{x}^* .

(1) 设 \mathbf{b} 有很小的扰动 $\delta\mathbf{b}$, 此时解 \mathbf{x}^* 变为 $\mathbf{x}^* + \delta\mathbf{x}^*$, 即有

$$\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*) = \mathbf{b} + \delta\mathbf{b}.$$

注意到 $\mathbf{Ax}^* = \mathbf{b}$, 则得

$$\mathbf{A}\delta\mathbf{x}^* = \delta\mathbf{b},$$

即

$$\delta\mathbf{x}^* = \mathbf{A}^{-1}\delta\mathbf{b}.$$

两边取范数并由矩阵范数性质得

$$\|\delta\mathbf{x}^*\| \leq \|\mathbf{A}^{-1}\| \|\delta\mathbf{b}\|.$$

另一方面, 由方程 $\mathbf{Ax}^* = \mathbf{b}$ 可得

$$\|\mathbf{b}\| \leq \|\mathbf{A}\| \|\mathbf{x}^*\|.$$

从而有

$$\frac{\|\delta\mathbf{x}^*\|}{\|\mathbf{x}^*\|} \leq \|\mathbf{A}^{-1}\| \|\mathbf{A}\| \frac{\|\delta\mathbf{b}\|}{\|\mathbf{b}\|}. \quad (6)$$

(2) 设 \mathbf{A} 有微小变化 $\delta\mathbf{A}$, 解变为 $\mathbf{x}^* + \delta\mathbf{x}^*$. 即

$$(\mathbf{A} + \delta\mathbf{A})(\mathbf{x}^* + \delta\mathbf{x}^*) = \mathbf{b}.$$

利用方程 $\mathbf{A}\mathbf{x}^* = \mathbf{b}$ 得

$$\delta\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*) + \mathbf{A}\delta\mathbf{x}^* = 0,$$

即

$$\delta\mathbf{x}^* = -\mathbf{A}^{-1}\delta\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*).$$

两边取范数得

$$\frac{\|\delta\mathbf{x}^*\|}{\|\mathbf{x}^* + \delta\mathbf{x}^*\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \frac{\|\delta\mathbf{A}\|}{\|\mathbf{A}\|}. \quad (7)$$

定义3.10

设 \mathbf{A} 为非奇异矩阵, 称 $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ 为矩阵 \mathbf{A} 的条件数, 记为

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|.$$

常用的条件数

$$(1) \text{cond}(\mathbf{A})_{\infty} = \|\mathbf{A}\|_{\infty} \|\mathbf{A}^{-1}\|_{\infty}.$$

$$(2) \text{cond}(\mathbf{A})_2 = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}.$$

$$\text{当 } \mathbf{A} \text{ 对称正定时, } \text{cond}(\mathbf{A})_2 = \frac{\lambda_1}{\lambda_n}$$

其中, $\lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 和 $\lambda_{\min}(\mathbf{A}^T \mathbf{A})$ 分别为 $\mathbf{A}^T \mathbf{A}$ 的最大特征值和最小特征值, λ_1 和 λ_n 分别为 \mathbf{A} 的最大特征值和最小特征值.

定义3.11

对于方程组 $\mathbf{Ax} = \mathbf{b}$, 其中 \mathbf{A} 非奇异. 如果 \mathbf{A} 的条件数很大, 则称该方程组为病态 (坏条件) 方程组; 如果 \mathbf{A} 的条件数比较小, 则称该方程组为良态 (好条件) 方程组.

可以计算例3.2中矩阵的条件数 $\text{cond}(\mathbf{A})_{\infty} = 2$, 故例3.2中的方程组是良态的. 而例3.3中矩阵的条件数 $\text{cond}(\mathbf{A})_{\infty} = 22002$, 故例3.3中的方程组是病态的.

在实际中, 由于计算 \mathbf{A}^{-1} 很麻烦, 所以 $\text{cond}(\mathbf{A})$ 不容易计算. 但可以通过下面情形来判断病态矩阵:

1. 用列主元Gauss消去法时出现绝对值很小的主元.
2. 系数矩阵某些行(列)近似线性相关.
3. 系数矩阵元素间数量级相差很大, 且没有一定规律.

对于病态方程组, 一般可以采用

1. 双精度计算, 减少舍入误差;
2. 对方程组进行预处理. 即选择非奇异矩阵 \mathbf{D}, \mathbf{C} , 将方程组 $\mathbf{Ax} = \mathbf{b}$ 化为等价的方程组 $\mathbf{DAC}[\mathbf{C}^{-1}\mathbf{x}] = \mathbf{Db}$, 使 \mathbf{DAC} 的条件数比较小.

★方程组近似解可靠性的判别 设 $\tilde{\mathbf{x}}$ 为方程组 $\mathbf{Ax} = \mathbf{b}$ 的近似解, 记 $\mathbf{r} = \mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}$, 若 $\mathbf{r} = \mathbf{0}$, 则 $\tilde{\mathbf{x}}$ 为精确解. 一般 $\mathbf{r} \neq \mathbf{0}$.

问题 能否根据 $\|\mathbf{r}\|$ 的大小来判断近似解 $\tilde{\mathbf{x}}$ 的精确程度?

定理3.10

设 $\tilde{\mathbf{x}}$ 是方程组 $\mathbf{Ax} = \mathbf{b}$ 的一个近似解, \mathbf{x}^* 为精确解, $\mathbf{r} = \mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}$. 则

$$\frac{\|\mathbf{x}^* - \tilde{\mathbf{x}}\|}{\|\mathbf{x}^*\|} \leq \text{cond}(\mathbf{A}) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}.$$

3.3 线性方程组的迭代法

★迭代格式的构造

设 \mathbf{A} 非奇异, $\mathbf{b} \neq \mathbf{0}$. 考虑方程组 $\mathbf{Ax} = \mathbf{b}$, 设其解为 \mathbf{x}^* . 将方程组改写为等价的方程

$$\mathbf{x} = \mathbf{Bx} + \mathbf{f}$$

这里 \mathbf{B} 为 n 阶方阵, $\mathbf{f} \in \mathbf{R}^n$. 任取一个向量 $\mathbf{x}^{(0)} \in \mathbf{R}^n$, 产生迭代

$$\mathbf{x}^{(k+1)} = \mathbf{Bx}^{(k)} + \mathbf{f}, \quad k = 0, 1, 2, \dots \quad (8)$$

上式产生一个向量序列 $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$. 若它收敛于 $\bar{\mathbf{x}}$, 即

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \bar{\mathbf{x}},$$

(8)两边取极限得 $\bar{\mathbf{x}} = \mathbf{B}\bar{\mathbf{x}} + \mathbf{f}$, 它等价于 $\mathbf{A}\bar{\mathbf{x}} = \mathbf{b}$. 故 $\bar{\mathbf{x}}$ 是原方程组的解, 即 $\mathbf{x}^* = \bar{\mathbf{x}}$.

(8)称为迭代格式, \mathbf{B} 为迭代矩阵. 若迭代格式(8)对任意初始向量 $\mathbf{x}^{(0)}$ 产生的迭代序列 $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ 均收敛, 称该迭代收敛.

问题:

1. 怎样构造迭代格式?
2. 迭代何时收敛?

★三个常用的迭代格式 将线性方程组 $\mathbf{Ax} = \mathbf{b}$ 写为分量形式

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2$$

$$a_{31}x_1 + a_{32}x_2 + \cdots + a_{3n}x_n = b_3$$

$$\vdots$$

$$a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n$$

假设 $a_{ii} \neq 0$ ($i = 1, 2, \dots, n$).

在上述方程组中第 i 个方程求出 x_i 得

$$x_1 = (b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n)/a_{11}$$

$$x_2 = (b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n)/a_{22}$$

$$x_3 = (b_3 - a_{31}x_1 - a_{32}x_2 - \cdots - a_{3n}x_n)/a_{33}$$

$$\vdots$$

$$x_n = (b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1})/a_{nn}$$

(1) Jacobi迭代格式

$$x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}$$

$$x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}$$

$$x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)} - \cdots - a_{3n}x_n^{(k)})/a_{33}$$

\vdots

$$x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})/a_{nn}$$

例子 用Jacobi迭代格式解方程组

$$\begin{pmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \\ 3 \end{pmatrix}$$

精确至3位有效数字.

解：Jacobi迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k)} - x_2^{(k)})/(-5). \end{cases}$$

取初始迭代向量 $x^{(0)} = (0, 0, 0)^T$, 各次迭代结果如下:

k	0	1	2	3	4	5	6
$x_1^{(k)}$	0.0000	0.1250	0.2500	0.2263	0.2235	0.2251	0.225
$x_2^{(k)}$	0.0000	0.4000	0.3150	0.3005	0.3060	0.3058	0.305
$x_3^{(k)}$	0.0000	-0.6000	-0.4950	-0.4870	-0.4946	-0.4941	-0.493

所以满足精度要求的近似解为 $x^* = (0.225, 0.306, -0.494)^T$.

下面将Jacobi迭代用矩阵和向量表示. 记

$$\mathbf{L} = \begin{bmatrix} 0 & & & & & \\ a_{21} & 0 & & & & \\ a_{31} & a_{32} & 0 & & & \\ \vdots & \vdots & \vdots & \ddots & & \\ a_{n-1,1} & a_{n-1,2} & a_{n-1,3} & \cdots & 0 & \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{n,n-1} & 0 \end{bmatrix},$$

$$\mathbf{D} = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & a_{33} & & \\ & & & \ddots & \\ & & & & a_{nn} \end{bmatrix},$$

$$\mathbf{U} = \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n,n-1} \\ & & & & 0 \end{bmatrix}.$$

则

$$\begin{aligned}\mathbf{A} &= \mathbf{L} + \mathbf{D} + \mathbf{U} \implies \\ \mathbf{Ax} &= \mathbf{b} \iff (\mathbf{L} + \mathbf{D} + \mathbf{U})\mathbf{x} = \mathbf{b} \\ \implies \mathbf{Dx} &= -(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{b} \\ \implies \mathbf{x} &= -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{D}^{-1}\mathbf{b}.\end{aligned}$$

Jacobi迭代:

$$\mathbf{x}^{(k+1)} = \mathbf{Jx}^{(k)} + \mathbf{f}_J, \quad k = 0, 1, \dots$$

其中

$$\mathbf{J} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad \mathbf{f}_J = \mathbf{D}^{-1}\mathbf{b}.$$

(2) **Gauss-Seidel**迭代格式 在Jacobi迭代中将已经求出的分量直接参加下一个分量的计算, 得到下面的Gauss-Seidel迭代.

$$x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}$$

$$x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}$$

$$x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - \cdots - a_{3n}x_n^{(k)})/a_{33}$$

\vdots

$$x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn}$$

例子 用Gauss-Seidel迭代格式解方程组

$$\begin{pmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 4 \\ 3 \end{pmatrix}$$

精确至3位有效数字.

解

Gauss-seidel迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k+1)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k+1)} - x_2^{(k+1)})/(-5). \end{cases}$$

取初始迭代向量 $x^{(0)} = (0, 0, 0)^T$, 各次迭代结果如下:

k	0	1	2	3	4
$x_1^{(k)}$	0.0000	0.1250	0.2344	0.2245	0.2250
$x_2^{(k)}$	0.0000	0.3750	0.3031	0.3059	0.3056
$x_3^{(k)}$	0.0000	-0.4925	-0.4925	-0.4939	-0.4936

所以满足精度要求的近似解为 $x^* = (0.225, 0.306, -0.494)^T$.

用矩阵表示为:

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \\ \implies (\mathbf{D} + \mathbf{L})\mathbf{x}^{(k+1)} &= \mathbf{b} - \mathbf{U}\mathbf{x}^{(k)}.\end{aligned}$$

Gauss-Seidel迭代:

$$\mathbf{x}^{(k+1)} = \mathbf{G}\mathbf{x}^{(k)} + \mathbf{f}_G, \quad k = 0, 1, \dots$$

其中

$$\mathbf{G} = -(\mathbf{D} + \mathbf{L})^{-1}\mathbf{U}, \quad \mathbf{f}_G = (\mathbf{D} + \mathbf{L})^{-1}\mathbf{b}.$$

★SOR（超松弛）迭代格式 已知 $\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$, 将Gauss-Seidel迭代得到的 $\mathbf{x}^{(k+1)}$ 与 $\mathbf{x}^{(k)}$ 加权平均, 得到SOR迭代:

$$\begin{aligned}x_1^{(k+1)} &= (1 - \omega)x_1^{(k)} \\&\quad + \omega(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)})/a_{11} \\x_2^{(k+1)} &= (1 - \omega)x_2^{(k)} \\&\quad + \omega(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)})/a_{22} \\&\vdots \\x_n^{(k+1)} &= (1 - \omega)x_n^{(k)} \\&\quad + \omega(b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn}\end{aligned}$$

其中 ω 为松弛因子. 当 $\omega = 1$, 上式成为Gauss-Seidel迭代.

将SOR迭代用矩阵表示：

$$\begin{aligned} \mathbf{x}^{(k+1)} &= (1 - \omega)\mathbf{x}^{(k)} + \omega\mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \implies \\ \mathbf{D}\mathbf{x}^{(k+1)} &= (1 - \omega)\mathbf{D}\mathbf{x}^{(k)} + \omega(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \implies \\ (\mathbf{D} + \omega\mathbf{L})\mathbf{x}^{(k+1)} &= [(1 - \omega)\mathbf{D} - \omega\mathbf{U}]\mathbf{x}^{(k)} + \omega\mathbf{b}, \implies \\ \mathbf{x}^{(k+1)} &= \mathbf{S}_\omega\mathbf{x}^{(k)} + \mathbf{f}_\omega. \end{aligned}$$

其中

$$\mathbf{S}_\omega = (\mathbf{D} + \omega\mathbf{L})^{-1}[(1 - \omega)\mathbf{D} - \omega\mathbf{U}], \quad \mathbf{f}_\omega = \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{b}.$$

★迭代格式的收敛性

迭代法基本定理

定理3.11

迭代格式 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ ($k = 0, 1, 2, \dots$) 收敛 $\iff \rho(\mathbf{B}) < 1$.

证明:

例3.4

给定线性方程组

$$\begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 1 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

- (a) 分别写出求解该方程组的 *Jacobi* 迭代和 *Gauss-Seidel* 迭代格式.
- (b) 分析这两种迭代格式的收敛性.

解

(a) Jacobi迭代格式:

$$\begin{aligned}x_1^{(k+1)} &= -\frac{1}{2}x_2^{(k)} - \frac{1}{2}x_3^{(k)}, \\x_2^{(k+1)} &= -\frac{1}{2}x_1^{(k)} - \frac{1}{2}x_3^{(k)} + 1, \quad k = 0, 1, \dots \\x_3^{(k+1)} &= -\frac{1}{2}x_1^{(k)} - \frac{1}{2}x_2^{(k)} + 1.\end{aligned}$$

Gauss-Seidel迭代格式为:

$$\begin{aligned}x_1^{(k+1)} &= -\frac{1}{2}x_2^{(k)} - \frac{1}{2}x_3^{(k)}, \\x_2^{(k+1)} &= -\frac{1}{2}x_1^{(k+1)} - \frac{1}{2}x_3^{(k)} + 1, \quad k = 0, 1, \dots \\x_3^{(k+1)} &= -\frac{1}{2}x_1^{(k+1)} - \frac{1}{2}x_2^{(k+1)} + 1.\end{aligned}$$

(b) Jacobi迭代矩阵 \mathbf{J} 的特征方程是

$$\begin{vmatrix} \lambda & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \lambda & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & \lambda \end{vmatrix} = 0. \implies 4\lambda^3 - 3\lambda + 1 = 0.$$
$$\implies (2\lambda - 1)(2\lambda^2 + \lambda - 1) = 0, \implies \rho(\mathbf{J}) = 1.$$

故Jacobi迭代发散.

Gauss-Seidel迭代矩阵 \mathbf{G} 的特征方程是

$$\begin{vmatrix} \lambda & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2}\lambda & \lambda & \frac{1}{2} \\ \frac{1}{2}\lambda & \frac{1}{2}\lambda & \lambda \end{vmatrix} = 0. \implies \lambda(8\lambda^2 - 2\lambda + 1) = 0.$$
$$\implies \lambda_1 = 0, \lambda_{2,3} = \frac{1 \pm \sqrt{7}i}{8}, \quad \rho(\mathbf{G}) = \frac{1}{\sqrt{8}} < 1.$$

所以Gauss-Seidel迭代收敛.

例3.5

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$, \mathbf{A} 为 n 阶非奇异矩阵. 构造迭代

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega(\mathbf{b} - \mathbf{Ax}^{(k)}), \quad (k = 0, 1, 2, \dots)$$

其中 $\omega \neq 0$ 为常数.

(a) 证明: 如果迭代收敛, 则迭代序列 $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ 收敛于方程 $\mathbf{Ax} = \mathbf{b}$ 的解.

(b) 设 $\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}$, 则 ω 取何值时迭代收敛?

定义3.12

设

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

如果

$$|a_{ii}| > \sum_{\substack{j=1 \\ i \neq j}}^n |a_{ij}|, \quad i = 1, 2, \dots, n$$

则称 A 按行严格对角占优；如果

$$|a_{jj}| > \sum_{\substack{i=1 \\ j \neq i}}^n |a_{ij}|, \quad j = 1, 2, \dots, n$$

则称 A 按列严格对角占优。按行严格对角占优或按列严格对角占优统称为严格对角占优。

引理 设A是严格对角占优的, 则 $|A| \neq 0$.

证明: 这里仅证A是按行严格对角占优的情况. 用反证法.

设 $|A| = 0$, 则齐次方程组 $Ax = 0$ 有非零解 $x^* = (x_1^*, x_2^*, \dots, x_n^*)^T$.

设 $\|x^*\|_\infty = |x_k^*| \neq 0$. 由第k个方程

$$a_{kk}x_k^* + \sum_{j=1, j \neq k}^n a_{kj}x_j^* = 0$$

可得

$$\begin{aligned} |a_{kk}| \cdot |x_k^*| &= \left| \sum_{j=1, j \neq k}^n a_{kj}x_j^* \right| \leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_j^*| \\ &\leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_k^*| \end{aligned}$$

两边约去 $|x_k^*|$, 得

$$|a_{kk}| \leq \sum_{j=1, j \neq k}^n |a_{kj}|$$

与按行严格对角占优矛盾. 因而 $|A| \neq 0$.

定理3.12

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$, 如果 \mathbf{A} 是严格对角占优矩阵, 则Jacobi迭代格式收敛.

证明: 记

$$B(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则Jacobi迭代矩阵 J 的特征方程为 $|B(\lambda)| = 0$. 设 A 是按行严格对角占优的, 则当 $|\lambda| \geq 1$ 时, 有

$$|\lambda a_{ii}| \geq |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$$

即 $B(\lambda)$ 是严格按行对角占优的。由上面的一个引理可知, 当 $|\lambda| \geq 1$ 时, $|B(\lambda)| \neq 0$. 换句话说, 方程 $|B(\lambda)| = 0$ 的 n 个根 $\lambda_1, \lambda_2, \dots, \lambda_n$ 都应满足 $|\lambda_i| < 1, i = 1, 2, \dots, n$. 于是 $\rho(J) < 1$. 同样可证当 A 按列严格对角占优的情况。因而Jacobi迭代格式收敛。

定理3.13

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$, 如果 \mathbf{A} 是严格对角占优矩阵, 则 Gauss-Seidel 迭代格式收敛.

证明: 记

$$C(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则 Gauss-Seidel 迭代矩阵 G 的特征方程为 $|C(\lambda)| = 0$. 设 A 是按行严格对角占优的, 则当 $|\lambda| \geq 1$ 时, 有

$$\begin{aligned} |\lambda a_{ii}| &= |\lambda| |a_{ii}| > |\lambda| \sum_{j=1, j \neq i}^n |a_{ij}| \\ &\geq |\lambda| \sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^n |a_{ij}| \quad i = 1, 2, \dots, n \end{aligned}$$

即 $C(\lambda)$ 是严格按行对角占优的。由上面的一个引理可知，当 $|\lambda| \geq 1$ 时， $|C(\lambda)| \neq 0$ 。换句话说，方程 $|C(\lambda)| = 0$ 的 n 个根 $\lambda_1, \lambda_2, \dots, \lambda_n$ 都应满足 $|\lambda_i| < 1, i = 1, 2, \dots, n$ 。于是 $\rho(G) < 1$ 。同样可证当 A 按列严格对角占优的情况。因而Gauss-Seidel迭代格式收敛。

3) SOR迭代的收敛性

SOR迭代的迭代矩阵为

$$S_\omega = (\mathbf{D} + \omega \mathbf{L})^{-1}[(1 - \omega)\mathbf{D} - \omega \mathbf{U}],$$

由定理3.11, SOR迭代收敛 $\iff \rho(S_\omega) < 1$.

定理3.14

SOR迭代收敛的必要条件是 $0 < \omega < 2$.

证 设 S_ω 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则由线性代数知

$$|\det(S_\omega)| = |\lambda_1 \lambda_2 \cdots \lambda_n| \leq \rho(S_\omega)^n.$$

另一方面, 由定理3.11, 若SOR收敛, 则 $\rho(S_\omega) < 1$, 从而有 $|\det(S_\omega)| < 1$. 而行列式

$$\begin{aligned} \det(S_\omega) &= \det[(\mathbf{D} + \omega \mathbf{L})^{-1}] \det[(1 - \omega)\mathbf{D} - \omega \mathbf{U}] \\ &= \left(\prod_{i=1}^n a_{ii} \right)^{-1} \prod_{i=1}^n [(1 - \omega)a_{ii}] \\ &= (1 - \omega)^n. \end{aligned}$$

从而有

$$|(1 - \omega)^n| < 1, \implies 0 < \omega < 2.$$

定理3.15

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$. 如果 \mathbf{A} 对称正定, 且 $0 < \omega < 2$, 则SOR迭代收敛.

注1 如果 \mathbf{A} 对称正定, 则Gauss-Seidel迭代收敛.

注2 SSOR:

$$\begin{aligned} \mathbf{x}^{(k+1/2)} &= (1 - w)\mathbf{x}^{(k)} + \omega \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1/2)} - \mathbf{L}^T \mathbf{x}^{(k)}), \\ \mathbf{x}^{(k+1)} &= (1 - w)\mathbf{x}^{(k+1/2)} + \omega \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1/2)} - \mathbf{L}^T \mathbf{x}^{(k+1)}) \end{aligned}$$

3.4 幂法与反幂法

幂法和反幂法是迭代法. 幂法用于求矩阵按模最大的特征值和对应的特征向量. 当特征值非零时, 反幂法用于求按模最小的特征值和对应的特征向量.

★求主特征值的幂法 设 $\mathbf{A} = (a_{ij})_{n \times n}$ 是 n 阶方阵, 它有 n 个线性无关的特征向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, 对应的特征值为 $\lambda_j (j = 1, 2, \dots, n)$, 按模的大小排列

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|,$$

其中 λ_1 是主特征值. 给定初值非零向量 \mathbf{v}_0 , 构造迭代

$$\mathbf{v}_k = \mathbf{A}\mathbf{v}_{k-1}, \quad k = 1, 2, \dots.$$

\mathbf{v}_0 可由 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 线性表示. 设表示为

$$\mathbf{v}_0 = \sum_{i=1}^n a_i \mathbf{x}_i,$$

且 $a_1 \neq 0$. 因此有

$$\mathbf{v}_k = \mathbf{A}\mathbf{v}_{k-1} = \mathbf{A}^k \mathbf{v}_0 = \mathbf{A}^k \sum_{i=1}^n a_i \mathbf{x}_i = \sum_{i=1}^n a_i \lambda_i^k \mathbf{x}_i, \quad k = 1, 2, \dots.$$

1) 特征值满足 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$. 则

$$\begin{aligned}\mathbf{v}_k &= \lambda_1^k \left[a_1 \mathbf{x}_1 + a_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}_2 + \cdots + a_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}_n \right] \\ \mathbf{v}_{k+1} &= \lambda_1^{k+1} \left[a_1 \mathbf{x}_1 + a_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k+1} \mathbf{x}_2 + \cdots + a_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k+1} \mathbf{x}_n \right]\end{aligned}$$

因为

$$|\lambda_1| > |\lambda_i| \quad i = 2, 3, \cdots, n,$$

故

$$\lim_{k \rightarrow \infty} \left(\frac{\lambda_i}{\lambda_1} \right)^k = 0, \quad i = 2, 3, \cdots, n.$$

从而当 k 充分大, 有

$$\mathbf{v}_k \approx a_1 \lambda_1^k \mathbf{x}_1, \quad \mathbf{v}_{k+1} \approx a_1 \lambda_1^{k+1} \mathbf{x}_1 \approx \lambda_1 \mathbf{v}_k. \quad (9)$$

由上式知 $\mathbf{v}_{k+1} = \mathbf{A} \mathbf{v}_k \approx \lambda_1 \mathbf{v}_k$. 该式说明 \mathbf{v}_k 是 λ_1 对应的近似特征向量, \mathbf{v}_k 和 \mathbf{v}_{k+1} 近似线性相关. 所以

$$\lambda_1 = \lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_i}{(\mathbf{v}_k)_i},$$

实际计算时，为了避免 \mathbf{v}_k 的分量产生溢出，可以采用“归一化”，具体将算法改为：

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0 \\ \mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1} \\ m_k = \max(\mathbf{v}_k) \\ \mathbf{u}_k = \mathbf{v}_k / m_k \end{cases} \quad k = 1, 2, \dots \quad (10)$$

其中 $m_k = \max \mathbf{v}_k$ 表示 \mathbf{v}_k 中(首次出现的)绝对值最大的分量.

定理3.16

设 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 则由算法(10)产生的序列 $\{\mathbf{u}_k\}$ 和 $\{m_k\}$ 均收敛, 且

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}, \quad \lim_{k \rightarrow \infty} m_k = \lambda_1.$$

证

$$\mathbf{u}_k = \frac{1}{m_k} \mathbf{v}_k = \frac{1}{m_k} \mathbf{A} \mathbf{u}_{k-1}, \quad k = 1, 2, \dots,$$

利用上式递推得

$$\begin{aligned} \mathbf{u}_k &= \frac{1}{m_k} \mathbf{A} \left(\frac{1}{m_{k-1}} \mathbf{A} \mathbf{u}_{k-2} \right) \\ &= \frac{1}{m_k m_{k-1}} \mathbf{A}^2 \mathbf{u}_{k-2} \\ &= \dots \\ &= \frac{1}{m_k m_{k-1} \cdots m_1} \mathbf{A}^k \mathbf{u}_0. \end{aligned}$$

由 \mathbf{u}_k 的归一化, $m_k m_{k-1} \cdots m_1 = \frac{\max(\mathbf{A}^k \mathbf{u}_0)}{\max(\mathbf{u}_k)} = \max(\mathbf{A}^k \mathbf{u}_0)$,

$$\begin{aligned}\mathbf{u}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)} \\&= \frac{\lambda_1^k \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left(\lambda_1^k \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right) \right)} \\&= \frac{a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}.\end{aligned}$$

从而

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}.$$

同样

$$\begin{aligned}\mathbf{v}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^{k-1} \mathbf{u}_0)} \\ &= \frac{\lambda_1 \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^{k-1} \mathbf{x}_i \right)}.\end{aligned}$$

因此

$$\lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

收敛速率: $\left| \frac{\lambda_2}{\lambda_1} \right|$

例3.6

用幂法计算矩阵

$$A = \begin{bmatrix} 2 & 3 & 2 \\ 10 & 3 & 4 \\ 3 & 6 & 1 \end{bmatrix}$$

的主特征值及对应的特征向量。

解： 取 $\mathbf{u}_0 = (0, 0, 1)^T$ ，由幂法公式 $\mathbf{v}_1 = A\mathbf{u}_0 = (2, 4, 1)^T$ ，可知

$$m_1 = 4, \mathbf{u}_1 = (0.5, 1.0, 0.25)^T.$$

依次迭代,得如下结果

k	\mathbf{u}_k^T (归一化向量)	$m_k = \max(\mathbf{v}_k)$
0	(0.0000, 0.0000, 1.0000)	1.0000
1	(0.5000, 1.0000, 0.2500)	4.0000
2	(0.5000, 1.0000, 0.8611)	9.0000
3	(0.5000, 1.0000, 0.7306)	11.4400
4	(0.5000, 1.0000, 0.7535)	10.9224
5	(0.5000, 1.0000, 0.7493)	11.0140
6	(0.5000, 1.0000, 0.7501)	10.9927
7	(0.5000, 1.0000, 0.7500)	11.0004
8	(0.5000, 1.0000, 0.7500)	11.0000

Table: 幂法求矩阵A的主特征值

矩阵A的三个特征值为11, -3, -2.

2) 当 $|\lambda_1| = |\lambda_2|$, 且 $|\lambda_2| > |\lambda_3|$ 时.

(a) $\lambda_1 = \lambda_2$.

$$\begin{aligned}\mathbf{u}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)} \\ &= \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i}{\max\left(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i\right)}\end{aligned}$$

因此

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2}{\max(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2)}.$$

$$\lim_{k \rightarrow \infty} m_k = \lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

收敛率: $\left|\frac{\lambda_3}{\lambda_1}\right|$.

(b) $\lambda_1 = -\lambda_2$

$$\begin{aligned}\mathbf{u}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)} \\ &= \frac{a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i}{\max\left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i\right)}\end{aligned}$$

其中 $|a_1| + |a_2| \neq 0$, 当 $a_2 \neq 0$ 时 \mathbf{u}_k 不收敛。

$$\mathbf{A}^2 \mathbf{u}_k = \lambda_1^2 \frac{a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^{k+2} \mathbf{x}_i}{\max\left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i\right)}$$

$$\lim_{k \rightarrow \infty} \max(\mathbf{A}^2 \mathbf{u}_k) = \lim_{k \rightarrow \infty} \lambda_1^2 \frac{\max \left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^{k+2} \mathbf{x}_i \right)}{\max \left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}$$

收斂率: $\left| \frac{\lambda_3}{\lambda_1} \right|$.

$$\mathbf{A} \mathbf{u}_k + \lambda_1 \mathbf{u}_k = \frac{2\lambda_1 a_1 \mathbf{x}_1 + \sum_{i=3}^n a_i (\lambda_i + \lambda_1) \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)},$$

$$\mathbf{A} \mathbf{u}_k - \lambda_1 \mathbf{u}_k = \frac{(-1)^{k+1} 2\lambda_1 a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i (\lambda_i - \lambda_1) \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left(a_1 \mathbf{x}_1 + (-1)^k a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}$$

可以分別作為 $\lambda_1, -\lambda_1$ 所對應的特徵向量。

(c) $\lambda_1 = \bar{\lambda}_2$

$$\mathbf{v}_k = \lambda_1^k \left[a_1 \mathbf{x}_1 + a_2 \left(\frac{\bar{\lambda}_1}{\lambda_1} \right)^k \bar{\mathbf{x}}_1 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right],$$

因为 $|\frac{\lambda_i}{\lambda_1}| < 1$, 当 $k \rightarrow \infty$ 有

$$\begin{aligned}\mathbf{v}_k &\approx a_1 \lambda_1^k \mathbf{x}_1 + a_2 \bar{\lambda}_1^k \bar{\mathbf{x}}_1, \\ \mathbf{v}_{k+1} &\approx a_1 \lambda_1^{k+1} \mathbf{x}_1 + a_2 \bar{\lambda}_1^{k+1} \bar{\mathbf{x}}_1, \\ \mathbf{v}_{k+2} &\approx a_1 \lambda_1^{k+2} \mathbf{x}_1 + a_2 \bar{\lambda}_1^{k+2} \bar{\mathbf{x}}_1,\end{aligned}$$

分别乘以 $q = \lambda_1 \bar{\lambda}_1, p = -(\lambda_1 + \bar{\lambda}_1), 1$, 相加

$$\mathbf{v}_{k+2} + p\mathbf{v}_{k+1} + q\mathbf{v}_k \approx 0$$

特征值, 特征向量

$$\lambda_1 = -\frac{p}{2} + \sqrt{\frac{p^2}{4} - q},$$

$$\bar{\lambda}_1 = -\frac{p}{2} - \sqrt{\frac{p^2}{4} - q}.$$

对应的特征向量

$$\mathbf{v}_{k+1} - \bar{\lambda}_1 \mathbf{v}_k = \lambda_1^k (\lambda_1 - \bar{\lambda}_1) a_1 \mathbf{x}_1,$$

$$\mathbf{v}_{k+1} - \lambda_1 \mathbf{v}_k = \bar{\lambda}_1^k (\bar{\lambda}_1 - \lambda_1) a_1 \bar{\mathbf{x}}_1$$

幂法优缺点

1. 方法简单，对大型稀疏矩阵比较合适；
2. 收敛情况复杂，需预先进行分析；
3. 初值($a_1 \neq 0, |a_1| + |a_2| \neq 0$)选取不好，会影响收敛速度。

★反幂法 当 \mathbf{A} 非奇异时, \mathbf{A} 的特征值非零. \mathbf{A}^{-1} 的按模最大特征值就是 \mathbf{A} 的按模最小的特征值. 因此用幂法可以求 \mathbf{A}^{-1} 的按模最大的特征值即 \mathbf{A} 的按模最小的特征值, 这就是反幂法. 算法如下:

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0 \\ \mathbf{A}\mathbf{v}_k = \mathbf{u}_{k-1} \\ m_k = \max(\mathbf{v}_k) \\ \mathbf{u}_k = \mathbf{v}_k / m_k \end{cases} \quad k = 1, 2, \dots$$

易知

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_n}{\max(\mathbf{x}_n)}, \quad \lim_{k \rightarrow \infty} m_k = \frac{1}{\lambda_n}.$$